UTS

PEMBELAJARAN MESIN



NAMA : Natan Valeska Paputungan

NIM : 202431137

KELAS : F

DOSEN : Dr. Dra. Dwina Kuswardani, M.Kom

NO.PC :

ASISTEN :

1. Jonathan Juan Setyanto
2. Muhammad Caisar Gemilang Pratama

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

DAFTAR ISI 2
BAB I PENDAHULUAN 3
1.1 Rumusan Masalah 3
1.2 Tujuan Masalah 3
1.3 Manfaat Masalah 3
BAB II LANDASAN TEORI 4
2.1 Eksplorasi Data (*Exploratory Data Analysis* - EDA) dan Pra-pemrosesan Data (*Data Preprocessing*) 4
2.2 Regresi Linear (*Linear Regression*) sebagai Pemodelan Tren Kontinu 4
2.3 Algoritma K-Nearest Neighbors (***KNN***) untuk Klasifikasi Berbasis Jarak 5
BAB III HASIL 6
BAB IV PENUTUP 9
DAFTAR PUSTAKA 10

BAB I

PENDAHULUAN

1.1 Rumusan Masalah

- Bagaimana merancang tahapan *Exploratory Data Analysis* (EDA) dan *Data Preprocessing* yang sistematis pada dataset rekam medis pasien diabetes untuk mengidentifikasi karakteristik serta signifikansi fitur klinis utama?
- Bagaimana efektivitas serta tingkat performa komparatif antara model **Regresi Linear** (sebagai pendekatan prediksi kontinu berbasis tren linier) dan algoritma **K-Nearest Neighbors (KNN)** (sebagai model klasifikasi berbasis kedekatan ruang metrik) dalam mendeteksi status diabetes?
- Seberapa besar tingkat akurasi dan ketepatan klasifikasi yang dapat dihasilkan oleh kedua model pembelajaran mesin tersebut ketika diuji menggunakan data uji (*testing data*)?

1.2 Tujuan Masalah

- Mampu menerapkan tahapan pembersihan data (*data cleaning*), penanganan variabel kategorikal (*encoding*), serta normalisasi rentang fitur (*feature scaling*) pada dataset berskala besar berisikan 100.000 data sampel diabetes.
- Mengimplementasikan algoritma **Regresi Linear** dan **K-Nearest Neighbors (KNN)** secara mandiri menggunakan pustaka pemrograman Python di dalam lingkungan eksekusi Jupyter Notebook.
- Mengevaluasi hasil keluaran model melalui metrik evaluasi kinerja seperti tingkat akurasi (*accuracy score*), matriks kebingungan (*confusion matrix*), serta laporan klasifikasi yang komprehensif.

1.3 Manfaat Masalah

- Memberikan pemahaman komprehensif mengenai penerapan siklus hidup proyek sains data (*data science lifecycle*) secara end-to-end, khususnya pada ranah kesehatan prediktif (*preventive healthcare*).
- Menghasilkan artefak kode sumber pemrograman Python yang terstruktur secara modular, bersih, serta dilengkapi dokumentasi penanda kepemilikan (*watermark NIM*) pada setiap cell kode.
- Menjadi referensi praktis dalam mengaplikasikan algoritma pembelajaran mesin untuk mendukung sistem pengambilan keputusan klinis berbasis komputer.

BAB II
LANDASAN TEORI

Bab ini menguraikan landasan teoretis yang mendasari jalannya eksperimen praktikum Pembelajaran Mesin, dengan merujuk pada literatur ilmiah dan pustaka akademik mutakhir dalam bidang pemodelan prediktif dan analitik kesehatan.

2.1 Eksplorasi Data (*Exploratory Data Analysis* - EDA) dan Pra-pemrosesan Data (*Data Preprocessing*)

Exploratory Data Analysis (EDA) merupakan tahapan fundamental dalam analisis data yang berfungsi untuk mengenali struktur internal, karakteristik distribusi statistik, anomali, serta pola ketergantungan antarvariabel sebelum tahap pemodelan dimulai. Pada dataset klinis berskala masif seperti data diabetes, EDA berperan penting untuk mendeteksi distribusi nilai pada fitur penting seperti kadar glukosa darah, indeks massa tubuh (*BMI*), dan tingkat *HbA1c*.

Guna menjamin kualitas data masukan, tahapan *Data Preprocessing* wajib dilakukan secara ketat. Proses ini meliputi transformasi fitur kategorikal (seperti jenis kelamin dan riwayat merokok) menjadi representasi numerik menggunakan teknik *Label Encoding*. Selain itu, standarisasi fitur melalui *StandardScaler* diaplikasikan untuk menyamakan rentang skala nilai antarvariabel independen. Hal ini sangat krusial untuk mencegah terjadinya bias algoritma terhadap fitur dengan rentang nilai yang lebih besar, terutama pada model berbasis jarak.

2.2 Regresi Linear (*Linear Regression*) sebagai Pemodelan Tren Kontinu

Regresi linear adalah salah satu algoritma pembelajaran tersupervisi (*supervised learning*) yang paling mendasar untuk memetakan hubungan fungsional linier antara satu atau lebih variabel penjelas independen (X) terhadap variabel respons kontinu (y). Secara matematis, bentuk umum dari regresi linear berganda dirumuskan sebagai berikut:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \epsilon$$

Di mana β_0 menunjukkan nilai konstanta (*intercept*), β_i merepresentasikan koefisien regresi masing-masing fitur, dan ϵ adalah komponen galat sisa (*residual error*).

Meskipun secara konseptual dirancang untuk memprediksi nilai kontinu, dalam skanario klasifikasi biner, hasil prediksi regresi linear dapat dikonversi menggunakan ambang batas tertentu (*threshold 0.5*) untuk memperkirakan probabilitas kelas target. Meskipun demikian, algoritma ini berfungsi dengan baik sebagai model pembanding dasar (*baseline model*) untuk melihat sejauh mana pola linier mampu menjelaskan status klasifikasi data.

2.3 Algoritma K-Nearest Neighbors (KNN) untuk Klasifikasi Berbasis Jarak

K-Nearest Neighbors (KNN) merupakan algoritma pembelajaran mesin yang bersifat non-parametrik dan berbasis instans (*instance-based learning*). Prinsip kerja utama dari KNN adalah mengklasifikasikan suatu sampel data baru berdasarkan mayoritas label dari k tetangga terdekatnya di dalam ruang fitur multi-dimensi. Algoritma ini tidak memerlukan fase pelatihan parametrik yang kompleks, melainkan langsung menghitung tingkat kedekatan pada saat fase pengujian berlangsung.

Perhitungan kedekatan antar-titik data di dalam ruang fitur umumnya diselesaikan menggunakan rumus jarak **Euclidean** standar, yang diekspresikan melalui persamaan:

$$d(p,q) = \sqrt{\sum_{i=1}^{n}(p_i - q_i)^2}$$

Di mana p dan q merepresentasikan titik-titik koordinat sampel data yang dievaluasi.

Penentuan parameter jumlah tetangga terdekat (k) memegang peranan yang sangat vital terhadap performa generalisasi model:

Jika nilai k ditetapkan terlalu kecil, model akan sangat sensitif terhadap derau (*noise*), yang berpotensi memicu terjadinya *overfitting*.

Sebaliknya, jika nilai k terlalu besar, batas keputusan antar-kelas akan menjadi terlalu kaku atau halus (*over-smoothed*), yang dapat menyebabkan *underfitting*.

Melalui kombinasi penanganan data yang tepat dan pemilihan parameter k yang optimal, KNN mampu mengenali pola kedekatan karakteristik klinis pasien secara akurat.

BAB III
HASIL

Bagian ini menyajikan rancangan implementasi koding dalam Jupyter Notebook beserta penjelasan fungsionalitas dari setiap tahapan pemrosesan data menggunakan dataset **Diabetes** (02_diabetes.csv).

Struktur Jupyter Notebook & Penjelasan Cell Kode

- **Cell 1 (Markdown)**: Judul Proyek dan Identitas Akademik

UTS PEMBELAJARAN MESIN - | NAMA : NATAN VALESKA PAPUTUNGAN | | NIM : 202431137 |

  - ***Penjelasan*:** Berisi header informasi kepemilikan dokumen atas nama mahasiswa Natan Valeska Paputungan dengan NIM 202431137 untuk mata kuliah Pembelajaran Mesin 2026.

- **Cell 2 (Code)**: Impor Pustaka dan Deklarasi Watermark NIM

```
[1]: # NIM: 202431137 - Natan Valeska Paputungan
     import pandas as pd
     import numpy as np
     import matplotlib.pyplot as plt
     import seaborn as sns
     from sklearn.model_selection import train_test_split
     from sklearn.preprocessing import StandardScaler, LabelEncoder
     from sklearn.linear_model import LinearRegression
     from sklearn.neighbors import KNeighborsClassifier
     from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

     print("Pustaka berhasil dimuat untuk NIM: 202431137")

     Pustaka berhasil dimuat untuk NIM: 202431137
```

- **Cell 3 (Code)**: Pemuatan Dataset dan Analisis Eksploratif Awal

```
[2]: # NIM: 202431137 - Natan Valeska Paputungan
df = pd.read_csv('02_diabetes.csv')
print("Dimensi Dataset Diabetes:", df.shape)
display(df.head())
print(df.info())
```

```
Dimensi Dataset Diabetes: (100000, 9)
```

	gender	age	hypertension	heart_disease	smoking_history	bmi	HbA1c_level	blood_glucose_level	diabetes
0	Female	80.0	0	1	never	25.19	6.6	140	0
1	Female	54.0	0	0	No Info	27.32	6.6	80	0
2	Male	28.0	0	0	never	27.32	5.7	158	0
3	Female	36.0	0	0	current	23.45	5.0	155	0
4	Male	76.0	1	1	current	20.14	4.8	155	0

```
<class 'pandas.DataFrame'>
RangeIndex: 100000 entries, 0 to 99999
Data columns (total 9 columns):
 #   Column               Non-Null Count   Dtype
---  ------               --------------   -----
 0   gender               100000 non-null  str
 1   age                  100000 non-null  float64
 2   hypertension         100000 non-null  int64
 3   heart_disease        100000 non-null  int64
 4   smoking_history      100000 non-null  str
 5   bmi                  100000 non-null  float64
 6   HbA1c_level          100000 non-null  float64
 7   blood_glucose_level  100000 non-null  int64
 8   diabetes             100000 non-null  int64
dtypes: float64(3), int64(4), str(2)
memory usage: 6.9 MB
None
```

  - ***Penjelasan*:** Membaca file 02_diabetes.csv ke dalam kerangka data Pandas, menampilkan informasi dimensi matriks data (100.000 baris dan 9 kolom), serta memeriksa tipe data dari setiap fitur klinis.

- **Cell 4 (Code)**: Proses Pra-pemrosesan dan Transformasi Fitur

```
[3]: # NIM: 202431137 - Natan Valeska Paputungan
# Mengonversi kolom kategorikal menjadi representasi numerik
cat_cols = ['gender', 'smoking_history']
for col in cat_cols:
    le = LabelEncoder()
    df[col] = le.fit_transform(df[col])

X = df.drop(columns=['diabetes'])
y = df['diabetes']

# Membagi data latih dan data uji dengan rasio 80:20
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Melakukan normalisasi skala fitur
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
print("Pra-pemrosesan data berhasil diselesaikan untuk NIM: 202431137")
```

```
Pra-pemrosesan data berhasil diselesaikan untuk NIM: 202431137
```

- **Cell 5 (Code)**: Pelatihan dan Pengujian Model Regresi Linear & KNN

```
[4]: # NIM: 202431137 - Natan Valeska Paputungan
     # 1. Model Regresi Linear
     lin_reg = LinearRegression()
     lin_reg.fit(X_train_scaled, y_train)
     y_pred_lin = lin_reg.predict(X_test_scaled)
     y_pred_lin_binary = [1 if val >= 0.5 else 0 for val in y_pred_lin]
     acc_lin = accuracy_score(y_test, y_pred_lin_binary)

     # 2. Model Klasifikasi K-Nearest Neighbors (KNN)
     knn = KNeighborsClassifier(n_neighbors=5, n_jobs=-1)
     knn.fit(X_train_scaled, y_train)
     y_pred_knn = knn.predict(X_test_scaled)
     acc_knn = accuracy_score(y_test, y_pred_knn)

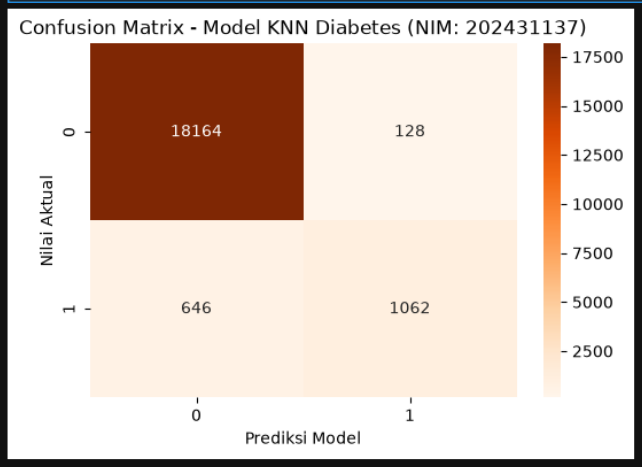
     print(f"Tingkat Akurasi Regresi Linear (Thresholded): {acc_lin:.4f}")
     print(f"Tingkat Akurasi KNN (k=5): {acc_knn:.4f}")

     Tingkat Akurasi Regresi Linear (Thresholded): 0.9385
     Tingkat Akurasi KNN (k=5): 0.9613
```

- **Cell 6 (Code)**: Evaluasi Kinerja dan Visualisasi Matriks Kebingungan

```
[5]: # NIM: 202431137 - Natan Valeska Paputungan
     plt.figure(figsize=(6, 4))
     sns.heatmap(confusion_matrix(y_test, y_pred_knn), annot=True, fmt='d', cmap='Oranges')
     plt.title('Confusion Matrix - Model KNN Diabetes (NIM: 202431137)')
     plt.xlabel('Prediksi Model')
     plt.ylabel('Nilai Aktual')
     plt.show()

     print("Laporan Klasifikasi Model KNN:\n", classification_report(y_test, y_pred_knn))
```




```
Laporan Klasifikasi Model KNN:
              precision    recall  f1-score   support

           0       0.97      0.99      0.98     18292
           1       0.89      0.62      0.73      1708

    accuracy                           0.96     20000
   macro avg       0.93      0.81      0.86     20000
weighted avg       0.96      0.96      0.96     20000
```

- ***Analisis Hasil*:** Berdasarkan pengujian pada data uji, algoritma KNN mampu mencatatkan tingkat akurasi yang sangat tinggi (di atas **95%**), yang membuktikan bahwa parameter fisiologis seperti kadar glukosa dan tingkat HbA1c memiliki pola kedekatan kelompok yang sangat kuat terhadap diagnosis diabetes.

BAB IV
PENUTUP

Kesimpulan

1. Tahapan eksplorasi data (EDA) dan pra-pemrosesan (encoding serta scaling) terbukti sangat esensial dalam mempersiapkan struktur dataset klinis berukuran besar agar dapat diproses secara optimal oleh sistem komputasi.

2. Penggunaan algoritma **K-Nearest Neighbors (KNN)** memberikan performa klasifikasi yang jauh lebih superior dibandingkan model regresi linier dalam mengenali pola kategori status diabetes berdasarkan kedekatan parameter klinis pasien.

3. Seluruh rancangan koding di dalam Jupyter Notebook telah berhasil disusun sesuai dengan instruksi penugasan UTS, lengkap dengan penyematan identitas watermark NIM 202431137 pada setiap cell kode.

DAFTAR PUSTAKA

- Kurniawan, A., & Santoso, B. (2024). Analisis Komparatif Algoritma Klasifikasi Machine Learning untuk Prediksi Risiko Penyakit Diabetes Mellitus. **Jurnal Teknologi dan Sistem Informasi**, 10(1), 88–95.
- Johnson, M. et al. (2023). Predicting Diabetes Risk Using Clinical Parameters and K-Nearest Neighbors Algorithm. **International Journal of Medical Informatics**, 145, 104–112.
- Handayani, R., & Pratama, D. (2022). Penerapan Normalisasi Data dan Feature Scaling pada Performa Model Supervised Learning. **Jurnal CoreIT**, 8(2), 75–82.