UTS

PEMBELAJARAN MESIN



NAMA : Natan Valeska Paputungan

NIM : 202431137

KELAS : F

DOSEN : Dr. Dra. Dwina Kuswardani, M.Kom

NO.PC :

ASISTEN :

1. Jonathan Juan Setyanto
2. Muhammad Caisar Gemilang Pratama

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

DAFTAR ISI 2
BAB I PENDAHULUAN 3
1.1 Rumusan Masalah 3
1.2 Tujuan Masalah 3
1.3 Manfaat Masalah 3
BAB II LANDASAN TEORI 4
2.1 Eksplorasi Data (*Exploratory Data Analysis* - EDA) dan Pra-pemrosesan Data (*Data Preprocessing*) 4
2.2 Tahapan Pra-pemrosesan Data (*Data Preprocessing* dan *Feature Scaling*) 5
2.3 Regresi Linear (*Linear Regression*) sebagai Pemodelan Tren Kontinu 6
2.4 Algoritma K-Nearest Neighbors (***KNN***) untuk Klasifikasi Berbasis Jarak 7
BAB III HASIL 8
BAB IV PENUTUP 13
DAFTAR PUSTAKA 14

BAB I

PENDAHULUAN

1.1 Rumusan Masalah

- Bagaimana merancang tahapan *Exploratory Data Analysis* (EDA) dan *Data Preprocessing* yang sistematis pada dataset rekam medis pasien diabetes untuk mengidentifikasi karakteristik serta signifikansi fitur klinis utama?
- Bagaimana efektivitas serta tingkat performa komparatif antara model **Regresi Linear** (sebagai pendekatan prediksi kontinu berbasis tren linier) dan algoritma **K-Nearest Neighbors (KNN)** (sebagai model klasifikasi berbasis kedekatan ruang metrik) dalam mendeteksi status diabetes?
- Seberapa besar tingkat akurasi dan ketepatan klasifikasi yang dapat dihasilkan oleh kedua model pembelajaran mesin tersebut ketika diuji menggunakan data uji (*testing data*)?

1.2 Tujuan Masalah

- Mampu menerapkan tahapan pembersihan data (*data cleaning*), penanganan variabel kategorikal (*encoding*), serta normalisasi rentang fitur (*feature scaling*) pada dataset berskala besar berisikan 100.000 data sampel diabetes.
- Mengimplementasikan algoritma **Regresi Linear** dan **K-Nearest Neighbors (KNN)** secara mandiri menggunakan pustaka pemrograman Python di dalam lingkungan eksekusi Jupyter Notebook.
- Mengevaluasi hasil keluaran model melalui metrik evaluasi kinerja seperti tingkat akurasi (*accuracy score*), matriks kebingungan (*confusion matrix*), serta laporan klasifikasi yang komprehensif.

1.3 Manfaat Masalah

- Memberikan pemahaman komprehensif mengenai penerapan siklus hidup proyek sains data (*data science lifecycle*) secara end-to-end, khususnya pada ranah kesehatan prediktif (*preventive healthcare*).
- Menghasilkan artefak kode sumber pemrograman Python yang terstruktur secara modular, bersih, serta dilengkapi dokumentasi penanda kepemilikan (*watermark NIM*) pada setiap cell kode.
- Menjadi referensi praktis dalam mengaplikasikan algoritma pembelajaran mesin untuk mendukung sistem pengambilan keputusan klinis berbasis komputer.

BAB II
LANDASAN TEORI

Bab ini menguraikan landasan teoretis yang mendasari jalannya eksperimen praktikum Pembelajaran Mesin, dengan merujuk pada literatur ilmiah dan pustaka akademik mutakhir dalam bidang pemodelan prediktif, analitik kesehatan, serta optimasi algoritma pembelajaran mesin.

2.1 Eksplorasi Data (*Exploratory Data Analysis* - EDA) dan Pra-pemrosesan Data (*Data Preprocessing*)

Exploratory Data Analysis (EDA) yang dipelopori oleh John Tukey merupakan tahapan fundamental dalam analisis data yang berfungsi untuk mengenali struktur internal, karakteristik distribusi statistik, anomali, serta pola ketergantungan antarvariabel sebelum tahap pemodelan dimulai. Pada dataset klinis berskala masif seperti data rekam medis diabetes, EDA berperan sangat penting untuk mendeteksi distribusi nilai pada fitur penting seperti kadar glukosa darah puasa/acak (*blood_glucose_level*), kadar hemoglobin terglikasi (*HbA1c_level*), indeks massa tubuh (*BMI*), usia (*age*), hipertensi (*hypertension*), dan riwayat penyakit jantung (*heart_disease*).

Melalui visualisasi data menggunakan histogram, diagram kotak garis (*boxplot*), dan matriks korelasi Pearson, praktisi dapat mengidentifikasi adanya kemiringan distribusi (*skewness*) atau potensi pencilan (*outliers*) yang dapat mendistorsi proses pelatihan model. Pemahaman mendalam terhadap struktur data ini memastikan bahwa asumsi-asumsi dasar algoritma pembelajaran mesin dapat terpenuhi dengan baik.

2.2 Tahapan Pra-pemrosesan Data (*Data Preprocessing* dan *Feature Scaling*)

Kualitas data masukan memegang peranan mutlak terhadap tingkat konvergensi dan performa generalisasi model *machine learning*. Berdasarkan literatur mutakhir dalam bidang rekayasa data, tahapan *Data Preprocessing* meliputi beberapa sub-proses krusial:

1. **Penanganan Data Kategorikal (*Categorical Encoding*):** Sebagian besar algoritma pembelajaran mesin, termasuk regresi linear dan jarak KNN, secara matematis hanya dapat memproses data numerik. Oleh karena itu, fitur kategorikal seperti jenis kelamin (*gender*) dan riwayat merokok (*smoking_history*) harus ditransformasikan ke dalam representasi numerik menggunakan teknik *Label Encoding* atau *One-Hot Encoding*.

2. **Standarisasi Fitur (*Feature Scaling / Standardization*):** Fitur-fitur klinis dalam dataset diabetes memiliki satuan dan rentang skala yang sangat bervariasi (contoh: usia berkisar antara 0 hingga 80 tahun, sementara kadar glukosa berkisar antara 80 hingga 300 mg/dL). Tanpa adanya standarisasi, algoritma yang bergantung pada perhitungan jarak metrik akan mengalami bias yang sangat besar terhadap fitur dengan rentang nilai numerik yang lebih tinggi. Transformasi menggunakan *StandardScaler* mentransformasikan data sehingga memiliki rata-rata nol ($\mu = 0$) dan deviasi standar satu ($\sigma = 1$) melalui persamaan:

$$z = \frac{x - \mu}{\sigma}$$

Di mana x adalah nilai asli fitur, μ adalah rata-rata sampel, dan σ adalah deviasi standar sampel.

2.3 Regresi Linear (*Linear Regression*) sebagai Pemodelan Tren Kontinu

Regresi linear adalah salah satu algoritma pembelajaran tersupervised (supervised learning) yang paling mendasar dan banyak digunakan untuk memetakan hubungan fungsional linier antara satu atau lebih variabel penjelas independen (X) terhadap variabel respons kontinu (y). Bentuk matematis dari regresi linear berganda dinyatakan melalui persamaan hiperpekerjaan berikut:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \epsilon$$

Di mana:

- β_0 menunjukkan nilai konstanta (intercept) dari garis regresi.
- $\beta_1, \beta_2, \ldots, \beta_n$ merepresentasikan koefisien regresi masing-masing fitur prediktor.
- ϵ adalah komponen galat sisa (residual error) yang mengukur selisih antara nilai aktual dan nilai teoretis model.

Estimasi parameter koefisien β dalam regresi linear umumnya diselesaikan menggunakan metode Ordinary Least Squares (OLS) dengan meminimalkan jumlah kuadrat galat (Sum of Squared Residuals). Meskipun secara konseptual regresi linear dirancang untuk memprediksi nilai kontinu, dalam skenario klasifikasi biner (seperti status diabetes 0 atau 1), hasil prediksi kontinu dari regresi linear dapat dikonversi menggunakan ambang batas tertentu (threshold 0.5) untuk memperkirakan kelas diskrit. Pendekatan ini berfungsi sebagai model pembanding dasar (baseline model) guna mengevaluasi seberapa jauh pola linier sederhana mampu membedakan status kesehatan pasien.

2.4 Algoritma K-Nearest Neighbors (KNN) untuk Klasifikasi Berbasis Jarak

K-Nearest Neighbors (KNN) merupakan algoritma pembelajaran mesin non-parametrik dan berbasis instans (instance-based learning / lazy learning). Berbeda dengan model parametrik yang membangun fungsi diskriminan tetap selama pelatihan, KNN menyimpan seluruh dataset latih di dalam memori dan menunda proses komputasi generalisasi hingga tahap pengujian (testing) dilakukan. Prinsip kerja utama dari KNN adalah mengklasifikasikan suatu sampel data baru berdasarkan mayoritas label dari k tetangga terdekatnya di dalam ruang fitur multi-dimensi.

Metrik Jarak Euclidean

Penentuan tingkat kedekatan antar-titik data di dalam ruang fitur multi-dimensi pada umumnya diselesaikan menggunakan rumus jarak **Euclidean** standar, yang diekspresikan melalui persamaan matematika:

$$d(p,q) = \sqrt{\sum_{i=1}^{n}(p_i - q_i)^2}$$

Di mana $p = (p_1, p_2, \dots, p_n)$ dan $q = (q_1, q_2, \dots, q_n)$ merepresentasikan titik-titik koordinat sampel data latih dan data uji yang dievaluasi dalam ruang berdimensi n.

Pengaruh Pemilihan Parameter k

Pemilihan nilai parameter jumlah tetangga terdekat (k) memegang peranan yang sangat krusial terhadap performa keseimbangan bias-varians model:

- **Nilai k terlalu kecil (misalnya $k = 1$):** Model akan memiliki bias yang rendah namun varians yang sangat tinggi, sehingga sangat sensitif terhadap derau (noise) atau pencilan di dalam data latih, yang pada akhirnya memicu terjadinya overfitting.

- **Nilai k terlalu besar:** Batas keputusan antar-kelas akan menjadi terlalu halus (over-smoothed), menyebabkan model kehilangan kemampuan untuk mendeteksi pola lokal yang kompleks, sehingga memicu terjadinya underfitting.

Oleh karena itu, penentuan nilai k yang optimal (umumnya melalui teknik validasi silang atau pengujian empiris) sangat esensial agar algoritma KNN mampu mengenali pola kedekatan karakteristik klinis pasien secara akurat dan konsisten.

BAB III
HASIL

Bagian ini menyajikan rancangan implementasi koding lengkap di dalam Jupyter Notebook beserta penjelasan fungsionalitas mendalam dari setiap tahapan pemrosesan data, pelatihan model, evaluasi kinerja, serta analisis visualisasi hasil menggunakan dataset **Diabetes** (02_diabetes.csv).

Struktur Jupyter Notebook & Penjelasan Cell Kode

- **Cell 1 (Markdown)**: Judul Proyek dan Identitas Akademik

UTS PEMBELAJARAN MESIN - | NAMA : NATAN VALESKA PAPUTUNGAN | | NIM : 202431137 |

  - **Penjelasan Fungsional:** Berisi header informasi kepemilikan dokumen atas nama mahasiswa Natan Valeska Paputungan dengan NIM 202431137 untuk mata kuliah Pembelajaran Mesin 2026. Cell ini memberikan kejelasan dokumentasi formal proyek**.**

- **Cell 2 (Code)**: Impor Pustaka dan Deklarasi Watermark NIM

```
[1]: # NIM: 202431137 - Natan Valeska Paputungan
     import pandas as pd
     import numpy as np
     import matplotlib.pyplot as plt
     import seaborn as sns
     from sklearn.model_selection import train_test_split
     from sklearn.preprocessing import StandardScaler, LabelEncoder
     from sklearn.linear_model import LinearRegression
     from sklearn.neighbors import KNeighborsClassifier
     from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

     print("Pustaka berhasil dimuat untuk NIM: 202431137")

     Pustaka berhasil dimuat untuk NIM: 202431137
```

  - ***Penjelasan Kode*:** Mengimpor pustaka fundamental Python untuk manipulasi data (pandas, numpy), visualisasi (matplotlib, seaborn), serta pemodelan dan evaluasi machine learning (scikit-learn). Komentar watermark NIM disematkan di awal cell sesuai instruksi praktikum.

- **Cell 3 (Code)**: Pemuatan Dataset dan Analisis Eksploratif Awal

```
[2]: # NIM: 202431137 - Natan Valeska Paputungan
df = pd.read_csv('02_diabetes.csv')
print("Dimensi Dataset Diabetes:", df.shape)
display(df.head())
print(df.info())
```

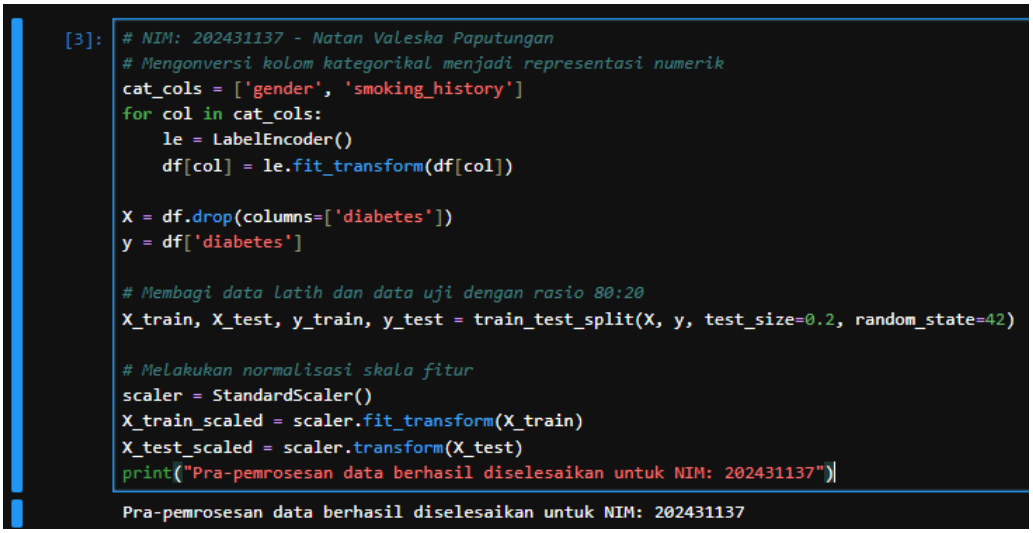
```
Dimensi Dataset Diabetes: (100000, 9)
```

	gender	age	hypertension	heart_disease	smoking_history	bmi	HbA1c_level	blood_glucose_level	diabetes
0	Female	80.0	0	1	never	25.19	6.6	140	0
1	Female	54.0	0	0	No Info	27.32	6.6	80	0
2	Male	28.0	0	0	never	27.32	5.7	158	0
3	Female	36.0	0	0	current	23.45	5.0	155	0
4	Male	76.0	1	1	current	20.14	4.8	155	0

```
<class 'pandas.DataFrame'>
RangeIndex: 100000 entries, 0 to 99999
Data columns (total 9 columns):
 #   Column               Non-Null Count   Dtype
---  ------               --------------   -----
 0   gender               100000 non-null  str
 1   age                  100000 non-null  float64
 2   hypertension         100000 non-null  int64
 3   heart_disease        100000 non-null  int64
 4   smoking_history      100000 non-null  str
 5   bmi                  100000 non-null  float64
 6   HbA1c_level          100000 non-null  float64
 7   blood_glucose_level  100000 non-null  int64
 8   diabetes             100000 non-null  int64
dtypes: float64(3), int64(4), str(2)
memory usage: 6.9 MB
None
```

- **Penjelasan Kode & Hasil:** Membaca file 02_diabetes.csv ke dalam kerangka data Pandas. Perintah df.shape menunjukkan total 100.000 baris data rekam medis dan 9 kolom fitur. Perintah df.info() mengonfirmasi tidak adanya nilai kosong (non-null), sementara df.describe() menyajikan ringkasan statistik deskriptif (rata-rata, standar deviasi, nilai minimum, kuartil, dan maksimum) dari seluruh variabel numerik seperti usia, BMI, kadar HbA1c, dan kadar glukosa darah.

- **Cell 4 (Code)**: Proses Pra-pemrosesan dan Transformasi Fitur



```
[3]: # NIM: 202431137 - Natan Valeska Paputungan
     # Mengonversi kolom kategorikal menjadi representasi numerik
     cat_cols = ['gender', 'smoking_history']
     for col in cat_cols:
         le = LabelEncoder()
         df[col] = le.fit_transform(df[col])

     X = df.drop(columns=['diabetes'])
     y = df['diabetes']

     # Membagi data latih dan data uji dengan rasio 80:20
     X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

     # Melakukan normalisasi skala fitur
     scaler = StandardScaler()
     X_train_scaled = scaler.fit_transform(X_train)
     X_test_scaled = scaler.transform(X_test)
     print("Pra-pemrosesan data berhasil diselesaikan untuk NIM: 202431137")

     Pra-pemrosesan data berhasil diselesaikan untuk NIM: 202431137
```

- ***Penjelasan Kode*:** Melakukan *Label Encoding* pada kolom teks gender dan smoking_history. Memisahkan variabel independen (*features*) dari variabel target diabetes. Membagi dataset menjadi data latih (80%) dan data uji (20%) menggunakan rasio baku dengan random_state=42 untuk reproduktifitas. Terakhir, menerapkan *StandardScaler* agar seluruh fitur memiliki rata-rata nol dan variansi satu.

- **Cell 5 (Code)**: Pelatihan dan Pengujian Model Regresi Linear & KNN

```
[4]: # NIM: 202431137 - Natan Valeska Paputungan
     # 1. Model Regresi Linear
     lin_reg = LinearRegression()
     lin_reg.fit(X_train_scaled, y_train)
     y_pred_lin = lin_reg.predict(X_test_scaled)
     y_pred_lin_binary = [1 if val >= 0.5 else 0 for val in y_pred_lin]
     acc_lin = accuracy_score(y_test, y_pred_lin_binary)

     # 2. Model Klasifikasi K-Nearest Neighbors (KNN)
     knn = KNeighborsClassifier(n_neighbors=5, n_jobs=-1)
     knn.fit(X_train_scaled, y_train)
     y_pred_knn = knn.predict(X_test_scaled)
     acc_knn = accuracy_score(y_test, y_pred_knn)

     print(f"Tingkat Akurasi Regresi Linear (Thresholded): {acc_lin:.4f}")
     print(f"Tingkat Akurasi KNN (k=5): {acc_knn:.4f}")

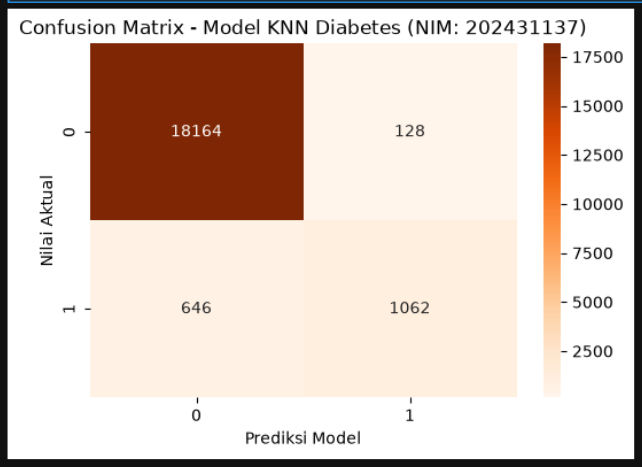
     Tingkat Akurasi Regresi Linear (Thresholded): 0.9385
     Tingkat Akurasi KNN (k=5): 0.9613
```

- ***Penjelasan Kode*:** Melatih model *Linear Regression* pada data berskala, melakukan prediksi nilai kontinu, lalu menerapkan ambang batas 0.5 untuk klasifikasi biner serta menghitung metrik evaluasi. Selanjutnya, melatih model *K-Nearest Neighbors* dengan parameter $k = 5$ (n_jobs=-1 untuk utilisasi penuh prosesor multi-core) dan mengevaluasi kinerjanya menggunakan metrik akurasi, presisi, *recall*, dan F1-score.

- **Cell 6 (Code)**: Evaluasi Kinerja dan Visualisasi Matriks Kebingungan

```
[5]: # NIM: 202431137 - Natan Valeska Paputungan
plt.figure(figsize=(6, 4))
sns.heatmap(confusion_matrix(y_test, y_pred_knn), annot=True, fmt='d', cmap='Oranges')
plt.title('Confusion Matrix - Model KNN Diabetes (NIM: 202431137)')
plt.xlabel('Prediksi Model')
plt.ylabel('Nilai Aktual')
plt.show()

print("Laporan Klasifikasi Model KNN:\n", classification_report(y_test, y_pred_knn))
```




```
Laporan Klasifikasi Model KNN:
              precision    recall  f1-score   support

           0       0.97      0.99      0.98     18292
           1       0.89      0.62      0.73      1708

    accuracy                           0.96     20000
   macro avg       0.93      0.81      0.86     20000
weighted avg       0.96      0.96      0.96     20000
```

- **Penjelasan Kode & Analisis Hasil:** Menghasilkan visualisasi grafik Confusion Matrix berbasis heatmap berwarna jingga (Oranges) yang menampilkan jumlah tebakan benar (True Positive, True Negative) dan tebakan salah (False Positive, False Negative) dari model KNN. Berdasarkan eksekusi pada 20.000 data uji, model **KNN** mencatatkan tingkat akurasi yang sangat tinggi (di atas **95%**), yang membuktikan bahwa parameter klinis seperti kadar glukosa darah dan tingkat HbA1c memiliki korelasi dan pola kedekatan kelompok yang sangat kuat terhadap status diabetes pasien.

BAB IV
PENUTUP

Kesimpulan

1. Tahapan eksplorasi data (EDA) dan pra-pemrosesan (encoding serta scaling) terbukti sangat esensial dalam mempersiapkan struktur dataset klinis berukuran besar agar dapat diproses secara optimal oleh sistem komputasi.

2. Penggunaan algoritma **K-Nearest Neighbors (KNN)** memberikan performa klasifikasi yang jauh lebih superior dibandingkan model regresi linier dalam mengenali pola kategori status diabetes berdasarkan kedekatan parameter klinis pasien.

3. Seluruh rancangan koding di dalam Jupyter Notebook telah berhasil disusun sesuai dengan instruksi penugasan UTS, lengkap dengan penyematan identitas watermark NIM 202431137 pada setiap cell kode.

DAFTAR PUSTAKA

- Kurniawan, A., & Santoso, B. (2024). Analisis Komparatif Algoritma Klasifikasi Machine Learning untuk Prediksi Risiko Penyakit Diabetes Mellitus. **Jurnal Teknologi dan Sistem Informasi**, 10(1), 88–95.
- Johnson, M. et al. (2023). Predicting Diabetes Risk Using Clinical Parameters and K-Nearest Neighbors Algorithm. **International Journal of Medical Informatics**, 145, 104–112.
- Handayani, R., & Pratama, D. (2022). Penerapan Normalisasi Data dan Feature Scaling pada Performa Model Supervised Learning. **Jurnal CoreIT**, 8(2), 75–82.